中国农业大学本科生毕业论文（设计）开题报告

学院：信息与电气工程学院　　专业：计算机科学与技术

学号：2022308250211　　年级：2022 级

学 生 姓 名	葛鑫锦	指 导 教 师	吕春利
论文（设计）题目	面向非独立同分布数据的自适应差分隐私联邦学习方法研究		

一、研究课题介绍

随着移动互联网与物联网技术的飞速发展，海量数据在边缘终端（如移动设备、IoT 传感器）呈爆发式增长，这些数据普遍面临“数据孤岛”与隐私敏感的双重约束。传统的集中式机器学习依赖于收集原始数据进行训练，不仅带来巨大的通信与存储开销，更引发了严重的数据泄露风险与合规性挑战（如 GDPR 法规限制）。联邦学习（Federated Learning, FL）作为一种“数据不出本地、仅交换模型参数”的分布式协作范式，为隐私保护下的多方协同建模提供了有效路径。然而，在实际应用场景中，不同客户端的数据往往呈现显著的非独立同分布（Non-IID）特性（即统计异构性），导致全局模型在聚合时极易出现权重发散、收敛困难甚至精度大幅下降的问题。此外，现有的标准差分隐私保护机制通常采用固定强度的噪声注入，往往难以兼顾模型的高可用性与强隐私保护需求，导致“隐私—效能”权衡失调。

针对上述挑战，本课题将以“非独立同分布数据下的隐私保护与模型优化”为核心，重点开展自适应差分隐私联邦学习方法的研究。具体任务包括：

1. **构建异构仿真环境**：基于 MNIST、CIFAR-10 等公开基准数据集，通过 Dirichlet 分布划分等手段，模拟具有不同偏斜程度的 Non-IID 数据分布场景。
2. **设计自适应隐私机制**：突破传统固定噪声的局限，设计基于梯度的自适应差分隐私（Adaptive Differential Privacy）算法，根据模型训练阶段或参数敏感度动态调整噪声注入策略，在保障差分隐私约束（ϵ-DP）的前提下最大化模型效能。
3. **异构优化算法集成**：结合 FedProx、FedNova 等异构友好型算法，设计稳健的聚合策略，解决统计异构带来的模型漂移（Model Drift）问题，构建一套既能抵抗推断攻击又能适应异构数据分布的高效联邦训练系统。

本研究在科学上融合了分布式优化理论与隐私计算技术，对于推动可信人工智能的发展具有重要意义。理论层面，本课题提出的自适应隐私保护方法将有效缓解统计异构性对联邦学习性能的制约，为解决“隐私保护强度与模型预测精度”之间的内生矛盾提供新的理论视角与算法支撑。应用层面，本研究成果具有广泛的普适性，能够为金融风控、智慧医疗、边缘计算等对数据隐私极其敏感且数据分

布差异巨大的领域，提供可复现、可推广的分布式建模解决方案，助力打破数据壁垒，实现数据价值的安全共享。

二、与本课题有关的国内外研究情况

近年来，随着数据隐私安全与跨机构共享需求的日益迫切，联邦学习（Federated Learning, FL）作为一种新兴的分布式隐私保护机器学习范式，已成为解决数据分散与协同建模难题的关键技术[1]。在应用探索层面，学术界已在多领域验证了其有效性：Friha 等人提出了基于 FL 的物联网入侵检测系统（FELIDS），证实了该架构在隐私保护下检测网络攻击的可行性[2]；张秋思利用 FL 整合地理上分散的农情数据，显著提升了区域作物产量预测模型的泛化性能[3]；赵盎然则设计了针对农作物病虫害诊断的联邦计算框架，实现了跨主体的协作式诊断[4]。此外，Žalik 等人通过对比研究指出，相较于传统集中式训练，联邦学习在特定智能场景中能够有效降低时间成本并提升模型精度[5]。然而，现有研究多侧重于验证联邦学习在特定任务中的可行性，往往基于理想化的通信与计算环境假设，忽略了实际部署中普遍存在的设备性能差异与数据分布不均问题[6]。

针对联邦学习在实际应用中面临的异构性挑战，学术界已提出了一系列优化算法以提升系统鲁棒性[7]。Li 等人提出的 FedProx 算法通过在本地目标函数中引入近端项（Proximal term），限制本地模型更新与全局模型的偏离程度，从而缓解由系统异构和统计异构导致的收敛不稳定性[8]；Wang 等人提出的 FedNova 算法则通过归一化本地更新梯度，有效消除了不同客户端因更新次数差异造成的全局聚合偏差[9]。具体到复杂应用场景，吴政娴和文娟的综述指出，数据显著的非独立同分布（Non-IID）特征以及终端（如传感器、嵌入式设备）算力资源的参差不齐，会导致直接应用 FedAvg 等基线算法时模型精度大幅下降[10]。尽管现有异构优化算法在通用数据集上表现尚可，但在高延迟、连接不稳定的弱网环境下，其鲁棒性仍有待提升，且目前鲜有研究能够有效兼顾时序与图像等多模态异构资源的协同处理。

在数据隐私保护机制方面，Kondaveeti 和 Mehta 系统分析了大数据分析面临的隐私威胁，主张采用差分隐私（Differential Privacy, DP）与安全聚合技术相结合的防御策略[11, 12]；PEFL 框架提出了一种基于深度隐私编码的方案，利用扰动编码技术实现敏感数据的特征隐藏[13]。然而，现有的隐私保护方法在实际应用中面临严峻的“隐私—效能”权衡挑战：一方面，引入同态加密等强密码学机制会产生过高的通信负载与计算开销，难以在资源受限的边缘终端上高效运行[14]；另一方面，简单的差分隐私噪声注入虽然计算成本较低，但过大的噪声会显著破坏精细化任务（如病害识别）的模型可用性[15]。综上所述，针对系统与统计异构并存以及强隐私约束的复杂工况，目前仍缺乏一种能够同时平衡模型精度、收敛速度与隐私预算的综合性解决方案。

综上所述，尽管现有研究已在联邦学习的异构性处理与隐私保护机制方面取得了初步进展，但在实际面对非独立同分布（Non-IID）数据与资源受限环境时，仍存在显著的局限性。具体而言，主要问题集中在以下三点：一是异构优化与模型收敛的挑战，现有的异构优化算法在极端 Non-IID 分布下对“客户端漂移”的抑制能力有限，且未充分解决引入隐私噪声后导致的模型不稳定性；二是隐私机制缺乏自适应性，传统的固定强度噪声注入策略（One-size-fits-all）无法感知模型训练阶段的动态变化与数据质量差异，难以在隐私合规与模型效能之间找到最佳平衡；三是通信开销与资源瓶颈，高频的参数交互与隐私加密操作带来了巨大的带宽压力，缺乏高效的传输优化手段以适应受限的网络环境。因此，如何设计一种能够自适应感知数据异构特征、动态调节隐私预算，并兼顾通信效率与模型精度的联邦学习方法，是当前亟需突破的关键科学问题，也是本研究重点所在。

参考文献

[1] Dembani R, Karvelas I, Akbar N A, et al. Agricultural data privacy and federated learning: A review of challenges and opportunities[J]. Computers and Electronics in Agriculture, 2025, 232: 110048.

[2] Friha O, Ferrag M A, Shu L, et al. FELIDS: Federated learning-based intrusion detection system for agricultural Internet of Things[J]. Journal of Parallel and Distributed Computing, 2022, 165: 17-31.

[3] 张秋思.基于联邦学习的玉米品种产量预测与适应性评价[D].安徽大学,2024.DOI:10.26917/d.cnki.ganhu.2024.000053.

[4] 赵盎然.基于联邦学习的玉米叶片病害识别方法研究[D].山东农业大学,2025.DOI:10.27277/d.cnki.gsdnu.2025.000661.

[5] Žalik K R, Žalik M. A review of federated learning in agriculture[J]. Sensors, 2023, 23(23): 9566.

[6] Chorney W, Rahman A, Wang Y, et al. Federated Learning for Heterogeneous Multi-Site Crop Disease Diagnosis[J]. Mathematics, 2025, 13(9): 1401.

[7] Ye M, Fang X, Du B, et al. Heterogeneous federated learning: State-of-the-art and research challenges[J]. ACM Computing Surveys, 2023, 56(3): 1-44.

[8] Yuan X, Li P. On convergence of fedprox: Local dissimilarity invariant bounds, non-smoothness and beyond[J]. Advances in Neural Information Processing Systems, 2022, 35: 10752-10765.

[9] Wang J, Liu Q, Liang H, et al. A novel framework for the analysis and design of heterogeneous federated learning[J]. IEEE Transactions on Signal Processing, 2021, 69: 5234-5249.

[10] 吴政娴,文娟.农业大数据与隐私计算技术研究综述[J].农业机械学报,2025,56(10):184-199+276.

[11] Kondaveeti H K, Sai G B, Athar S A, et al. Federated learning for smart agriculture: Challenges and opportunities[C]//2024 Third International Conference on Distributed Computing and Electrical Circuits and Electronics (ICDCECE). IEEE, 2024: 1-7.

[12] Mehta S, Kukreja V, Gupta A. Transforming Agriculture: Federated Learning CNNs for Wheat Disease Severity Assessment[C]//2023 8th International Conference on Communication and Electronics Systems (ICCES). IEEE, 2023: 792-797.

[13] Kumar P, Gupta G P, Tripathi R. PEFL: Deep privacy-encoding-based federated learning framework for smart agriculture[J]. IEEE Micro, 2021, 42(1): 33-40.

[14] Le D D, Dao M S, Tran A K, et al. Federated learning in smart agriculture: an overview[C]//2023 15th International Conference on Knowledge and Systems Engineering (KSE). IEEE, 2023: 1-4.

[15] 孔劼,周瀚磊,钟冬.分布式差分隐私的联邦学习方法研究[J].西安工业大学学报,2025,45(06):927-935.DOI:10.16185/j.jxatu.edu.cn.2025.06.301.

三、本课题所需要解决的问题

1. 非独立同分布（Non-IID）数据导致的全局模型发散与收敛困难问题

在联邦学习的实际应用场景中，不同客户端持有的数据往往呈现显著的统计异构性（Statistical Heterogeneity），即数据分布不满足独立同分布（IID）假设（如标签分布倾斜或特征分布差异）。传统的联邦平均算法（FedAvg）在聚合这些差异巨大的本地模型参数时，极易产生“客户端漂移”（Client Drift）现象，导致全局模型权重发散、收敛速度大幅降低甚至无法收敛。本课题首先需要解决的核心问题是：如何在数据高度偏斜的异构环境下，设计有效的算法优化策略，纠正本地更新偏差，确保全局模型在 Non-IID 数据上仍能保持稳健的收敛性和较高的预测精度。

2. 隐私保护机制引入后的“隐私—效能”权衡优化问题

为了防止恶意攻击者通过梯度反向推断用户隐私，引入差分隐私（Differential Privacy, DP）机制是必要的手段。然而，现有的 DP 联邦学习方法大多采用固定强度的噪声注入策略（One-size-fits-all），忽略了模型在不同训练阶段对噪声的敏感度差异以及不同客户端数据贡献度的异质性。这种“静态”机制往往导致两个极端：要么噪声过大导致模型精度雪崩式下跌，要么噪声不足以抵御高水平攻击。本课题需要解决如何设计自适应的噪声调节机制，根据梯度稀疏性、训练轮次以及数据质量动态分配隐私预算，在满足严格隐私合规（ϵ-DP）的前提下，最大化模型的预测效能，找到“隐私安全”与“模型精度”之间的最佳平衡点。

3. 分布式协作过程中的高通信开销与资源受限问题

联邦学习涉及大量的客户端与服务器之间的参数交互，随着模型深度的增加，传输的高维梯度向量会带来巨大的通信带宽压力。特别是在边缘计算或移动网络环境下，带宽受限和连接不稳定性是常

态。本课题需要解决如何在保障隐私和精度的同时，降低通信载荷。即研究如何在差分隐私框架下融合梯度压缩、量化或稀疏化技术，减少每一轮通信的数据传输量，从而缓解网络拥塞，提升联邦训练系统的整体通信效率与运行鲁棒性。

四、本课题研究的技术流程

1. 异构数据仿真环境构建与非独立同分布（Non-IID）场景模拟

基于 Python 语言与 PyTorch 深度学习框架搭建基础实验环境。选取 MNIST 与 CIFAR-10 等公开基准数据集作为实验对象。为了真实模拟实际应用中的统计异构性，本研究将采用基于 Dirichlet 分布（LDA）的数据划分策略，通过调整浓度参数（α）来控制不同客户端之间数据分布的偏斜程度（从轻度 Non-IID 到极端 Non-IID），同时，设定不同数量的客户端节点（如 10 个、50 个），构建出一个异构联邦学习仿真平台。

2. 自适应差分隐私机制的实现

改变传统差分隐私的固定高斯噪声或拉普拉斯噪声的注入方式，设计一种动态噪声调节机制。该机制将根据模型训练的全局轮次（Round）与本地梯度灵敏度（Sensitivity）进行双重自适应调整：在训练初期梯度较大时适当放宽隐私预算以加速收敛，在训练后期梯度收敛时增加噪声强度以防止过拟合与隐私泄露。同时，引入差分隐私会计机制，对每一轮的隐私消耗进行精确追踪与累积计算，确保总隐私预算（Total Privacy Budget, ϵ）控制在合规范围内。

3. 异构优化算法的设计

针对非独立同分布（Non-IID）数据分布极易引发的模型权重发散与客户端漂移问题，本研究致力于将前述设计的自适应隐私机制与 FedProx 等异构联邦优化算法进行深度融合，以构建稳健的训练框架。在本地训练阶段，研究将在损失函数中引入近端正则化项（Proximal Term），通过限制本地模型更新方向与全局模型参数的偏离程度，有效防止因数据分布极度偏斜而导致的模型过拟合现象。与此同时，在服务器聚合阶段，本研究将改进传统的平均聚合策略，设计一种自适应加权聚合算法，降低低质量或离群节点对全局模型的负面影响，确保模型即使在强隐私噪声的干扰下，依然能够保持稳健的收敛轨迹与较高的预测精度。

4. 通信压缩模块开发

为了突破联邦学习在实际网络环境中面临的带宽受限与通信延迟瓶颈，本研究将在隐私保护框架下深度集成基于 Top-k 的梯度稀疏化策略，仅筛选关键梯度参数进行加密与上传，从而过滤掉大量冗余信息。

5. 对比实验验证、消融分析与性能评估

- **评价指标**：本研究将综合采用测试集准确率与损失值、收敛轮次、通信传输载荷以及累积隐私预算（ϵ）等多维指标，从模型精度、系统运行效率与隐私保护强度三个层面进行全方位的量化评估。
- **对比实验**：基于 Flower 架构，集成上述模块构建完整的联邦学习原型系统，同时，为了验证方法的有效性，复现并调试多组基线方案作为对照组，包括：(1) 无隐私保护的 FedAvg（性能上限）；(2) 传统固定噪声的 DP-FedAvg；(3) 仅包含异构优化的 FedProx 与 FedNova。确保所有对比算法在相同的硬件环境、相同的 Non-IID 数据划分以及相同的超参数设置下运行，以保证实验结果的公平性与可复现性。
- **消融分析**：通过逐一移除或替换“自适应噪声调节机制”、“异构优化算法”以及“通信优化模块”，观察并记录单一变量变化对模型收敛速度、最终精度及通信开销的具体影响，从而定量分析各组件在应对统计异构与隐私保护问题时的边际贡献。
- **性能评估**：绘制“隐私（ϵ）—效能（Accuracy）”权衡曲线，量化评估在强隐私保护需求下模型性能的损耗情况。记录通信传输载荷（Communication Payload）与训练轮次（Communication Rounds），综合评估方法在弱网环境下的通信效率与计算鲁棒性，最终验证该方法在非独立同分布数据与资源受限场景下的综合优势。

五、预期结果及其意义

本课题预期将提出一套面向非独立同分布（Non-IID）数据的自适应差分隐私联邦学习算法框架，并完成从理论设计到系统实现的完整闭环。在技术产出方面，将构建一个基于 Flower 架构的高扩展性联邦仿真实验平台，成功集成自适应噪声调节、异构优化及通信压缩等核心模块；在实验成果方面，通过在 MNIST、CIFAR-10 等基准数据集上的广泛验证，输出一份包含模型精度、收敛速度、通信开销及隐私预算等关键指标的详细量化评估报告，并绘制精确的“隐私—效能”权衡曲线，证实所提方法相比于 FedAvg、FedProx 及传统 DP-FedAvg 等基线方案的优越性。最终，研究成果将汇编为一篇逻辑严谨的高质量毕业论文，并提供配套的、注释规范的可复现代码仓库与实验使用说明。

本研究的意义在于探索并验证了在统计异构与强隐私约束的双重挑战下，实现高效分布式协同建模的可行路径。从学术价值来看，课题创新性地引入自适应隐私机制，有效缓解了异构数据分布导致的模型发散难题，为解决“隐私保护强度与模型准确率”之间的内生矛盾提供了新的理论视角与算法

支撑；从应用价值来看，研究成果具有显著的普适性，不仅有助于打破多方数据孤岛，更能为金融风控、智慧医疗及边缘计算等对数据隐私极其敏感且数据分布差异巨大的领域，提供一套可落地、低通信成本且安全可信的分布式人工智能解决方案，对于推动可信 AI 技术的实际部署与发展具有重要的参考价值。

完成课题的各阶段工作具体安排

起止日期	本阶段的工作安排
2025 年 12 月-2026 年 1 月	文献调研与开题准备
2026 年 1 月-2026 年 2 月	环境搭建与数据预处理
2026 年 2 月-2026 年 3 月	核心算法设计与系统实现
2026 年 3 月-2026 年 4 月	实验仿真、优化与中期检查
2026 年 4 月-2026 年 5 月	材料整理与毕业论文撰写
2026 年 5 月-2026 年 6 月	定稿与毕业答辩

六、指导教师意见：

签名：

日期：